

Projeto Mensal 3 - Tratamento de Dados

Base SIM/DATASUS: óbitos de crianças de 0 a 4 anos em Foz do Iguaçu (PR)

Fonte oficial: <https://dadosabertos.saude.gov.br/dataset/sim>. Data de acesso: 16/05/2026.

1. Introdução

O projeto utiliza uma base real do Sistema de Informação sobre Mortalidade (SIM), mantido pelo Ministério da Saúde/DATASUS. A base bruta contém registros de óbitos infantis, com ano, município de residência, causa básica, idade, sexo, raça/cor e local de ocorrência. O foco do trabalho é preparar os dados antes de qualquer dashboard ou mineração, garantindo qualidade, padronização e documentação.

2. Tema escolhido

O tema escolhido foi mortalidade de crianças de 0 a 4 anos em Foz do Iguaçu (PR). A base permite analisar padrões por ano, idade, causa básica, sexo, raça/cor e local de ocorrência, o que torna o conjunto adequado para tratamento de dados e análise exploratória.

3. Fonte dos dados

A fonte é o Sistema de Informação sobre Mortalidade (SIM), disponibilizado pelo Ministério da Saúde/DATASUS. Link de referência: <https://dadosabertos.saude.gov.br/dataset/sim>. Data de acesso: 16/05/2026. A base original foi preservada em `dados_brutos/dadosSIM2005-.csv`.

4. Objetivo da análise

O objetivo é transformar uma base bruta em um dataset final confiável e documentado, com duplicidades removidas, valores ausentes tratados, categorias padronizadas, outliers analisados, novas variáveis criadas e evidências exploratórias suficientes para apoiar BI e Data Mining.

5. Descrição da base original

A base bruta possui 1110 registros e 9 colunas. As principais colunas originais são ano, sigla_uf, id_municipio_residencia, causa_basica, idade, sexo, raca_cor, escolaridade e local_ocorrendia. Há variáveis numéricas, categóricas codificadas e campos com valores ausentes, o que atende ao objetivo de tratamento do projeto.

6. Relação da base com BI, Big Data Analytics e Data Mining

Em Business Intelligence, a base pode alimentar dashboards com quantidade de óbitos por ano, faixa etária, causa básica, local de ocorrência, sexo e raça/cor. Em Big Data Analytics, o mesmo fluxo poderia ser ampliado para séries históricas nacionais do SIM, com alto volume, variedade de variáveis e atualização recorrente. Em Data Mining, as variáveis tratadas permitem agrupamento de perfis, descoberta de padrões por causa, classificação de registros por risco ou investigação de associações entre causa, idade e local de ocorrência.

6.1 Modelagem inicial dos dados

Item	Descrição
Linhas na base bruta	1110
Colunas na base bruta	9

Item	Descrição
Linhas no dataset final	1052
Colunas no dataset final	21
Dimensões para BI	ano, sexo_desc, raca_cor_desc, local_ocorrencia_desc, grupo_causa, faixa_etaria
Medidas para BI	total de óbitos, idade, idade_meses, indicadores booleanos


7. Diagnóstico da qualidade dos dados

Foram identificadas 58 linhas duplicadas, 1026 valores ausentes na base original e 91.16% de ausência em escolaridade. A coluna escolaridade foi removida por baixa completude; raça/cor ausente foi padronizada como Ignorada; categorias codificadas receberam descrições analíticas.


problema	colunas_afetadas	quantidade	decisao
Valores ausentes	raca_cor, escolaridade	1026	Preencher raça/cor como Ignorada; remover escolaridade por excesso de ausência.
Linhas duplicadas	Todas	58	Remover duplicidades exatas para evitar dupla contagem.
Coluna com baixa utilidade analítica	escolaridade	1010	Remover do dataset final, pois mais de 90% dos registros estão vazios.
Categorias codificadas	sexo, raca_cor, local_ocorrencia	3	Criar descrições padronizadas para uso em BI e análise exploratória.
Outliers estatísticos	idade	196	Calcular pelo método IQR após remoção de duplicidades e manter com coluna indic

8. Análise Exploratória de Dados


A análise mostrou que 895 registros (85.1%) são de menores de um ano, contra 157 registros de 1 a 4 anos. Também há predominância de ocorrências hospitalares (89.9% do total). A leitura temporal e a distribuição por causa ajudam a separar o que é volume geral do que é prioridade específica por faixa etária.




Distribuição anual de óbitos



Principais grupos de causa básica



Distribuição da idade no óbito



8.1 Cruzamentos relevantes para a análise

O cruzamento entre causa e faixa etária deixa a conclusão mais forte: afecções perinatais somam 468 registros e todos os 468 com faixa informada estão em menores de um ano. Já causas externas representam 4.1% dos óbitos em menores de um ano, mas sobem para 31.8% entre 1 e 4 anos. Isso indica dois focos diferentes: cuidado materno-infantil e neonatal para menores de um ano, e prevenção de acidentes/violências para crianças de 1 a 4 anos.

grupo_causa	Menor de 1 ano	1 a 4 anos	total_obitos
Afecções perinatais	468	0	468
Malformações congênicas	235	18	253
Causas externas	37	50	87
Aparelho respiratório	43	21	64
Doenças infecciosas e parasitárias	39	13	52
Sintomas e causas mal definidas	33	2	35
Sistema nervoso	11	18	29
Neoplasias e sangue	3	19	22


faixa_etaria_bi	total_obitos	causas_externas	percentual_causas_externas
1 a 4 anos	157	50	31.8
Menor de 1 ano	895	37	4.1

No cruzamento com local de ocorrência, sintomas e causas mal definidas chamam atenção: 48.6% desses registros ocorreram em domicílio. Esse ponto não deve ser lido apenas como volume, mas como sinal de qualidade do dado e necessidade de investigação mais cuidadosa da causa básica.


grupo_causa	total_obitos	percentual_hospitalar	percentual_domicilio
Afecções perinatais	468	98.1	1.3
Malformações congênicas	253	96.0	1.6

grupo_causa	total_obitos	percentual_hospitalar	percentual_domicilio
Causas externas	87	55.2	14.9
Aparelho respiratório	64	82.8	7.8
Doenças infecciosas e parasitárias	52	94.2	0.0
Sintomas e causas mal definidas	35	40.0	48.6
Sistema nervoso	29	79.3	13.8
Neoplasias e sangue	22	100.0	0.0

Grupo de causa por faixa etária



Peso das causas externas por faixa etária



9. Seleção das variáveis

Foram mantidas variáveis úteis para análise temporal, geográfica, demográfica, clínica e operacional. A coluna escolaridade foi descartada porque a ausência era muito alta e poderia induzir interpretações frágeis. No dataset final permaneceram variáveis originais relevantes e variáveis criadas para apoiar análise, como grupo_causa, idade_meses, faixa_etaria, causa_externa e indicadores de outlier.

10. Limpeza e pré-processamento

As duplicidades exatas foram removidas, textos foram padronizados, códigos foram convertidos para inteiros, a idade foi convertida para formato numérico e as categorias codificadas de sexo, raça/cor e local de ocorrência foram mapeadas para descrições legíveis. Esse pré-processamento preparou a base para análise exploratória e BI.

11. Tratamento de valores faltantes

Antes do tratamento havia valores ausentes em raça/cor e escolaridade. Depois do tratamento, o dataset final ficou sem valores ausentes: raça/cor recebeu a categoria Ignorada e escolaridade foi removida com justificativa técnica.

coluna	faltantes_antes	faltantes_depois
ano	0	0
causa_basica	0	0
causa_externa	0	0
classificacao_evitabilidade	0	0
escolaridade	1010	0
faixa_etaria	0	0
faixa_etaria_bi	0	0
grupo_causa	0	0
id_municipio_residencia	0	0
idade	0	0
idade_meses	0	0
idade_normalizada_minmax	0	0

12. Tratamento de outliers

O método IQR aplicado à idade gerou limite superior de 0.61 ano e identificou 196 registros como extremos estatísticos. Esses registros não foram tratados como erro automático, pois óbitos entre 1 e 4 anos são possíveis e relevantes. A decisão principal foi mantê-los no dataset final com a coluna idade_outlier_iqr e também gerar uma versão alternativa sem outliers.


Item	Valor
Q1 idade	0.01
Q3 idade	0.25
IQR	0.24
Limite superior	0.61
Registros sinalizados	196

Item	Valor
Decisão	Manter no dataset final e criar versão alternativa sem outliers

Para visualizar outliers sem distorcer a interpretação, foi usado um boxplot da idade em meses por grupo de causa. Essa versão é mais informativa que o boxplot único, pois mostra que alguns valores extremos não são erros: eles representam perfis diferentes de mortalidade, como causas externas e sistema nervoso ocorrendo em idades mais altas.

Boxplot da idade por grupo de causa

Idade em meses, por grupo de causa. Caixa = Q1 a Q3; linha vermelha = mediana; pontos = outliers do grupo.



13. Transformações realizadas

Foram criadas descrições para códigos de sexo, raça/cor e local de ocorrência; agrupamento de causa por capítulo simplificado do CID-10; idade em meses; indicadores de causa externa e óbito hospitalar; faixa etária para BI; e classificação simplificada de evitabilidade.

14. Agregações realizadas

A principal agregação resume o total de óbitos por ano. Ela ajuda a identificar anos com maior volume de registros e serve como base para dashboards temporais. Também foram geradas agregações por faixa etária, grupo de causa e local de ocorrência para sustentar os cruzamentos exploratórios.

ano	total_obitos
2005	79
2006	70
2007	72
2008	64
2009	59
2010	61
2011	44
2012	54

ano	total_obitos
2013	69
2014	62
2015	65
2016	52
2017	52
2018	46
2019	45
2020	43
2021	57
2022	58

15. Normalização e padronização

A variável idade foi normalizada com Min-Max Scaling, variando de 0 a 1, e também padronizada em z-score. A normalização facilita comparações em escala comum, enquanto o z-score indica quantos desvios padrão cada registro está distante da média. Essas duas versões são úteis para técnicas de Data Mining e Machine Learning.

16. Discretização

A variável numérica idade foi transformada em categorias analíticas. A coluna faixa_etaria separa registros em Neonatal, Pós-neonatal, 1 ano, 2 anos, 3 anos e 4 anos. A coluna faixa_etaria_bi consolida a leitura em Menor de 1 ano e 1 a 4 anos, facilitando a construção de filtros e gráficos em BI.

17. Feature Engineering

As principais variáveis criadas foram grupo_causa, classificacao_evitabilidade, idade_meses, faixa_etaria, faixa_etaria_bi, causa_externa, obito_hospitalar, idade_outlier_iqr, idade_normalizada_minmax e idade_padronizada_zscore. Essas features aumentam a utilidade analítica do dataset sem alterar a base original.

18. Descrição do dataset final

O dataset final está limpo, sem duplicidades exatas, sem valores faltantes, com nomes padronizados, variáveis originais relevantes e variáveis criadas. Ele possui 1052 registros e 21 colunas, pronto para uso em BI, Data Mining e análise exploratória.

19. Catálogo de dados

O catálogo de dados foi gerado em formato XLSX, CSV e Markdown. Ele documenta, para cada coluna do dataset final, o nome da coluna, descrição, tipo, exemplo, origem, tratamento aplicado e uso esperado na análise.

20. Organização DataOps

A organização do projeto preserva a base bruta, separa dados tratados, mantém o notebook/script reproduzível e concentra a documentação na pasta documentacao. Também foi gerada uma pasta final chamada PM3_Tratamento_Dados com os arquivos necessários para entrega e reprodução do processamento.

Pasta/arquivo	Finalidade
dados_brutos/	Base original preservada.
dados_tratados/	Dataset final tratado e versão sem outliers estatísticos.
notebooks/	Notebook tratamento_dados_pm3.ipynb.
documentacao/	Relatório final, catálogo, tabelas de evidências e gráficos.
projMens3.py	Script Python usado para reproduzir todo o processo.
README.md	Instruções de execução e descrição dos entregáveis.

21. Conclusão

A conclusão analítica principal é que a base não deve ser lida apenas pelo total de óbitos. O cruzamento das variáveis mostra perfis diferentes: menores de um ano estão mais associados a causas perinatais e malformações congênitas, enquanto a faixa de 1 a 4 anos apresenta peso proporcional muito maior de causas externas. Assim, um dashboard útil deveria separar esses grupos em vez de apresentar somente um ranking geral de causas.

Outro achado relevante é a relação entre local de ocorrência e qualidade da causa registrada: causas mal definidas têm participação domiciliar alta em relação aos principais grupos. Isso sugere que parte do uso da base em BI deve monitorar qualidade do preenchimento, não apenas indicadores finais de mortalidade.

22. Limitações

A base está restrita a um município e a classificação de evitabilidade usada no projeto é simplificada para fins didáticos, não substituindo protocolos oficiais de investigação epidemiológica. Além disso, a análise trabalha com contagens absolutas e não com taxas populacionais.

23. Próximos passos

Os próximos passos recomendados são cruzar o SIM com dados populacionais, calcular taxas por nascidos vivos, ampliar a comparação com outros municípios e construir um dashboard temporal com filtros por faixa etária, grupo de causa, local de ocorrência, sexo e raça/cor.